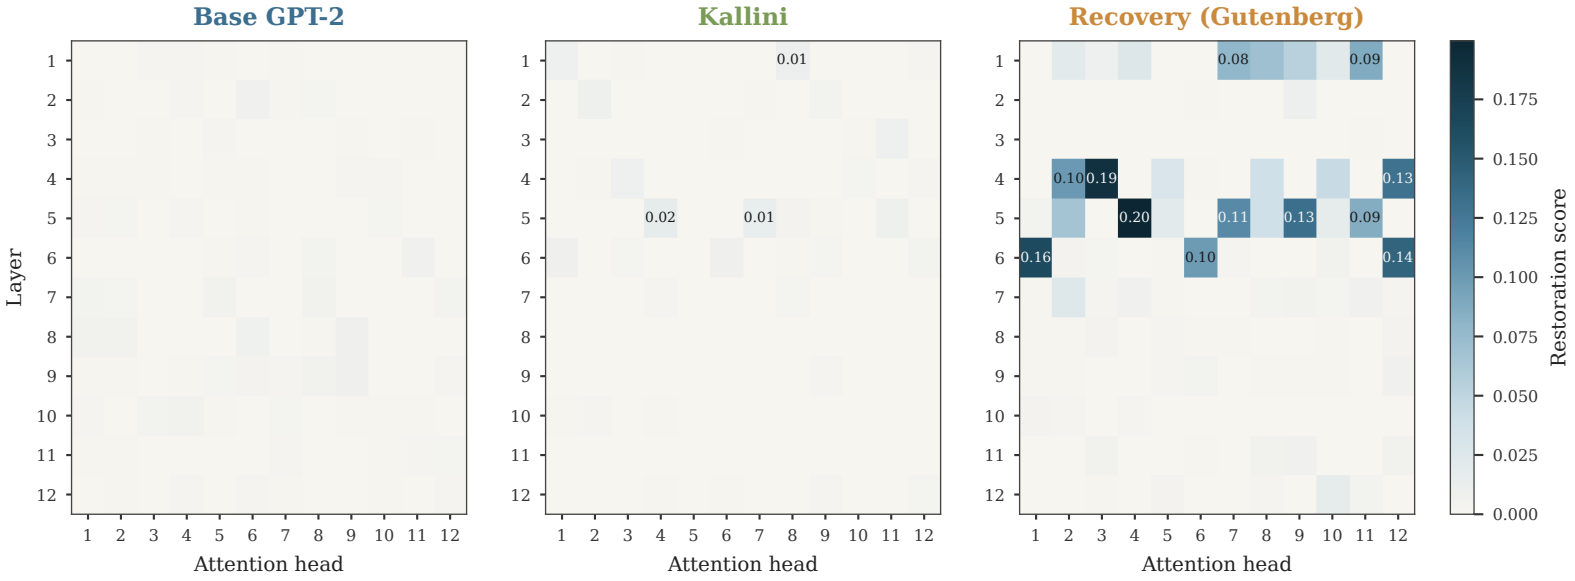
Reverse — head-level activation patching (Gutenberg)
Base GPT-2
Kallini
Recovery (Gutenberg)
Layer
Attention head
Restoration score
0.01
0.02
0.01
0.08
0.09
0.10
0.19
0.13
0.20
0.11
0.13
0.09
0.16
0.10
0.14
0.175
0.150
0.125
0.100
0.075
0.050
0.025
0.000